

# Klasifikasi Retakan (*Crack*) pada Bangunan dengan Analisis Citra Menggunakan Metode GLCM dan Klasifikasi SVM

*(Crack Classification of Buildings with Image Analysis Using the GLCM Method and SVM Classification)*

Chaerus Sulton, I Gede Pasek Sutawijaya, Ida Bagus Ketut Widiartha

Program Studi Teknik Informatika, Fakultas Teknik, Universitas Mataram

Jl. Majapahit 62, Mataram, Lombok NTB, INDONESIA

Email: chaerussulton@gmail.com, gpsutawijaya@unram.ac.id, widi@unram.ac.id

**Abstract** - Cracks classification on buildings caused by natural disasters such as earthquakes can be done manually by analyzing walls, poles, or floors based on diameter, depth, and length of cracks using vision. After that, it can be concluded to be a category of mild, moderate or severe cracks. This manual method requires enough knowledge and experience to be used. Only building structure experts can solve it. Whereas in the earthquake location, not everyone has the same knowledge and experience about cracks. To facilitate and overcome these problems, in this study a crack classification system will be developed with a digital image processing approach (pattern recognition) that can classify cracks into the light, medium or heavy categories, using extraction features of GLCM and classification of SVM. Based on the research that has been done, the accuracy obtained to classify the cracks reach until 70,37% up to 83,33%.

**Key words:** *Cracks, Image Analysis, Image Processing, GLCM, SVM.*

## I. PENDAHULUAN

Gempa bumi merupakan rentetan getaran dengan frekuensi tertentu yang terjadi di permukaan bumi akibat pelepasan energi dari dalam secara tiba-tiba yang menciptakan gelombang seismik. Gelombang seismik adalah rambatan energi yang disebabkan karena adanya gangguan di dalam kerak bumi, misalnya adanya patahan atau adanya ledakan. Sehingga wilayah yang masuk ke dalam getaran tersebut mengalami berbagai kerusakan seperti memicu tsunami, longsor, kerusakan infrastruktur sampai dengan kerusakan bangunan-bangunan. Begitu juga yang sedang dirasakan di daerah Kabupaten Lombok Utara, NTB. Terhitung mulai dari 29 Juli 2018 sampai dengan 30 Agustus 2018 saja menghasilkan 1.973 gempa bumi [1]. Daerah tersebut mengalami berbagai kerusakan mulai dari longsor, kerusakan infrastruktur maupun kerusakan bangunan. Pada bangunan sendiri, gempa bumi mengakibatkan terjadinya retakan-retakan (*crack*) baik ringan, sedang sampai dengan berat. Selain disebabkan oleh gempa bumi, kerusakan bangunan juga dapat disebabkan oleh usia bangunan yang terlampau tua, sehingga bangunan akan menjadi rapuh dan mudah

roboh. Maka diperlukan pendataan kembali apakah bangunan tersebut masih layak atau tidak.

Dalam melakukan upaya pendataan bangunan berdasarkan tingkat keretakannya, terdapat berbagai metode yang dapat dilakukan untuk mengategorikan suatu retakan (*crack*) masuk ke kategori retakan ringan, sedang atau berat. Metode yang mudah dan sering digunakan adalah metode pengamatan secara manual. Cara kerjanya yaitu mengamati bangunan yang terdampak gempa dengan menganalisis retakan yang berada di dinding, tiang, maupun lantai baik berdasarkan diameter retakan, kedalaman sampai dengan panjang retakan. Setelah itu dapat disimpulkan apakah retakan tersebut masuk ke dalam retakan ringan, sedang atau berat.

Metode pengamatan manual memiliki kekurangan karena membutuhkan pengetahuan dan pengalaman yang cukup untuk dapat digunakan. Sehingga hanya para ahli struktur (orang yang mempelajari struktur bangunan) yang dapat melakukannya. Sedangkan di lokasi gempa bumi sendiri tidak semua masyarakat memiliki pengetahuan dan pengalaman yang sama mengenai retakan (*crack*).

Untuk memudahkan masyarakat dan mengatasi masalah tersebut, maka dalam penelitian ini akan dibangun sistem klasifikasi retakan (*crack*) dengan pendekatan pengolahan citra digital (pengenalan pola) yang dapat mengategorikan suatu retakan masuk ke jenis ringan, sedang atau berat, menggunakan metode ekstraksi fitur GLCM serta klasifikasi SVM.

## II. TINJAUAN PUSTAKA

Penelitian dengan penggunaan *Gray Level Co-Occurrence Matrix* (GLCM) sebagai metode ekstraksinya telah dilakukan oleh beberapa peneliti di antaranya klasifikasi jenis daging sapi, kambing dan babi [2], klasifikasi batik [3], klasifikasi daging sapi, kerbau, kambing dan kuda [4], klasifikasi jenis kualitas keju [5], pengenalan tulisan tangan [6], kualitas daging sapi dengan menggunakan data *ultrasound image* [7], serta klasifikasi mutu jeruk keprok [8] menghasilkan akurasi

sebesar 73,3% untuk klasifikasi jenis daging sapi, kambing dan babi, 70% untuk klasifikasi batik, 87,5% untuk klasifikasi daging sapi, kerbau, kambing dan kuda, 97,9% untuk klasifikasi jenis kualitas keju, 95,2% untuk pengenalan tulisan tangan, 90% untuk kualitas daging sapi dengan menggunakan data *ultrasound image*, serta 82,5% untuk klasifikasi mutu jeruk keprok.

Pada jurnal dengan judul “*Crack detection using image processing: A critical review and analysis*” telah dilakukan *review* dan analisis terhadap 50 jurnal mengenai deteksi retakan menggunakan pemrosesan gambar [9]. Dari *review* ini ditemukan bahwa metode GLCM termasuk juga ke dalam metode yang direkomendasikan. Salah satunya pada jurnal dengan judul “*Imaging-based detection of AAR induced map-crack damage in concrete structure*” menghasilkan akurasi 75,2% [10].


Selanjutnya penelitian yang menggunakan *Support Vector Machine* (SVM) sebagai metode klasifikasi di antaranya adalah klasifikasi daging sapi, kerbau, kambing dan kuda [4], klasifikasi jenis kualitas keju [5], pengenalan tulisan tangan [6], kualitas daging sapi dengan menggunakan data *ultrasound image* [7], dan klasifikasi penyakit gigi dan mulut [11] menghasilkan akurasi sebesar 87,5% untuk klasifikasi daging sapi, kerbau, kambing dan kuda, 97,9% untuk klasifikasi jenis kualitas keju, 95,2% untuk pengenalan tulisan tangan, 90% untuk kualitas daging sapi dengan menggunakan data *ultrasound image*, serta 94,44% untuk klasifikasi penyakit gigi dan mulut.

Berdasarkan penelitian di atas, maka fitur tekstur retakan (*crack*) pada bangunan juga dapat diekstraksi dengan metode ekstraksi fitur GLCM serta klasifikasi dengan metode klasifikasi SVM. Sehingga pada penelitian ini akan dibangun sistem klasifikasi retakan (*crack*) pada bangunan dengan analisis citra menggunakan metode GLCM dan klasifikasi SVM.

### III. METODE PENELITIAN

#### A. Rancangan Algoritma

Sistem ini secara garis besar terdapat tiga proses utama yaitu *training* (pelatihan), *testing* (pengujian) dan klasifikasi. dapat dilihat pada Gambar 1.



Gambar 1. Proses training (pelatihan), testing (pengujian) dan klasifikasi

##### A.1. Tahap Preprocessing

Tahap *preprocessing* yang terdiri atas proses *Binarization*, *Morphological Filtering*, dan *Segmentation*. Setiap citra latih dan citra uji akan melewati tahapan awal

tersebut untuk menghilangkan dan mengurangi error yang dapat berdampak pada akurasi akhir pada saat masuk ke tahap klasifikasi.

##### 1. Binarization

Pada tahapan *binarization*, setiap pixel citra retakan akan diubah ke bentuk binary (0 dan 1), sehingga retakan (*crack*) akan tampak lebih jelas. Pada Gambar 2 merupakan tampilan dari perubahan citra asli ke citra binary.



Gambar 2. Perubahan citra asli ke citra binary

##### 2. Morphological Filtering


Pada tahapan ini, citra akan difilter dengan tujuan untuk menghilangkan bintik-bintik (*noise*) yang nantinya akan merusak kualitas citra. Jenis filtering yang digunakan adalah median filtering. Pada Gambar 3 merupakan tampilan dari perubahan citra yang telah melalui proses filter.



Gambar 3. Citra yang telah melalui proses filter

##### 3. Segmentation

Pada tahapan ini, citra akan di segmentasi untuk mengetahui posisi retakan (*crack*) yang selanjutnya akan dipotong, sehingga hanya citra retakan saja yang diolah. Pada Gambar 4 merupakan tampilan dari tahap segmentasi.



Gambar 4. Proses segmentasi

##### A2. Extraction Feature

Tahap selanjutnya yaitu *extraction feature* merupakan bagian dari teknik pengenalan pola (*pattern recognition*) yang bertujuan untuk mengambil atau mengekstraksi nilai-nilai unik dari suatu objek yang membedakan dengan objek yang lain. Penelitian ini menggunakan metode *extraction feature Gray Level Co-occurrence*

*Matrix (GLCM). Gray Level Co-occurrence Matrix* adalah matriks yang menggambarkan frekuensi munculnya pasangan dua *pixel* dengan intensitas tertentu dalam jarak (d) dan orientasi arah dengan sudut ( $\theta$ ) tertentu dalam citra [17].

Di dalam penelitiannya yang berjudul “*Textural Features for Image Classification*” [15], Haralick dkk. mengusulkan fitur tekstural yang mengandung informasi tentang karakteristik tekstur. Pada Tabel 1 menjelaskan rumus perhitungan fitur tersebut.

TABEL 1. TABEL FITUR TEKSTUR GLCM

| No. | Properti                                  | Rumus   | Persamaan |
|-----|---|---|-----------|
| 1   | Angular Second Moment : Energy/Uniformity | $f_1 = \sum_i \sum_j \{p(i, j)\}^2$   | (1)       |
| 2   | Contrast                                  | $f_2 = \sum_{n=0}^{Ng-1} n^2 \left\{ \sum_{i=1}^{Ng} \sum_{j=1}^{Ng} p(i, j) \right\}_{ i-j =n}$  | (2)       |
| 3   | Correlation                               | $f_3 = \frac{\sum_i \sum_j (ij) p(i, j) - \mu_x \mu_y}{\sigma_x \sigma_y}$<br>Dimana $\mu$ merupakan means dan $\sigma$ merupakan standar deviasi dari p. $N_g$ merupakan jumlah kolom/baris. $n$ jumlah pixel. $i$ merupakan baris ke- $i$ , $j$ merupakan kolom ke- $j$ . | (3)       |
| 4   | Sum of Squares : Variance                 | $f_4 = \sum_i \sum_j (i - \mu)^2 p(i, j)$   | (4)       |
| 5   | Inverse Difference Moment : Homogeneity   | $f_5 = \sum_i \sum_j \frac{1}{1 + (i - j)^2} p(i, j)$   | (5)       |
| 6   | Sum Average                               | $f_6 = \sum_{i=2}^{2Ng} i p_{x+y}(i)$   | (6)       |
| 7   | Sum Entropy                               | $f_7 = -\sum_{i=2}^{2Ng} p_{x+y}(i) \log\{p_{x+y}(i)\}$   | (7)       |
| 8   | Sum Variance                              | $f_8 = \sum_{i=2}^{2Ng} (i - f_7)^2 p_{(x+y)}(i)$   | (8)       |
| 9   | Entropy                                   | $f_9 = -\sum_i \sum_j p(i, j) \log(p(i, j))$  | (9)       |
| 10  | Difference Variance                       | $f_{10} = \text{variance of } p_{x+y}$  | (10)      |
| 11  | Difference Entropy                        | $f_{11} = -\sum_{i=0}^{Ng-1} p_{x-y}(i) \log\{p_{x-y}(i)\}$   | (11)      |
| 12  | Information                               | $f_{12} = \frac{HXY - HXY1}{\max\{H, X, Y\}}$   | (12)      |

|    |                                 |   |      |
|----|---------------------------------|---|------|
|    | Measures of Correlation         | $f_{13} = (1 - \exp[-2.0(HXY2 - HXY)])^{\frac{1}{2}}$   | (13) |
|    |                                 | $HXY = -\sum_i \sum_j p(i, j) \log(p(i, j))$  |      |
|    |                                 | Dimana HX dan HY adalah entropy dari $p_x$ dan $p_y$ , dan  |      |
|    |                                 | $HXY1 = -\sum_i \sum_j p(i, j) \log\{p_x(i) p_y(j)\}$   |      |
|    |                                 | $HXY2 = -\sum_i \sum_j p_x(i) p_y(j) \log\{p_x(i) p_y(j)\}$   |      |
| 13 | Maximal Correlation Coefficient | $f_{14} = (\text{Second largest eigenvalue of } Q_{(i,j)})$<br>dimana<br>$Q_{(i,j)} = \sum_k \frac{p(i,k)p(j,k)}{p_x(i)p_y(k)}$ | (14) |

Pada jurnal internasional dengan judul “*Efficient analysis of satellite image denoising and resolution enhancement for improving classification accuracy*”, terdapat 5 fitur yang paling baik untuk digunakan yaitu *Energy, Contrast, Correlation, Homogeneity* dan *Entropy* [16].

Proses ekstraksi fitur dengan metode GLCM dibagi menjadi dua tahap, yaitu pembentukan matriks GLCM dan perhitungan nilai fitur GLCM.

#### 1. Pembentukan matriks GLCM

Misalkan terdapat citra *grayscale* dengan matriks seperti pada Gambar 5.

$$A = \begin{bmatrix} 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 2 & 2 & 2 \\ 2 & 2 & 3 & 3 \end{bmatrix}$$

Gambar 5. Contoh matriks citra grayscale


Dari matriks di atas dibentuk matriks GLCM dengan orientasi sudut  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$ ,  $135^\circ$ . Adapun langkah-langkah pembentukan matriks GLCM sebagai berikut:

- Langkah pertama yaitu membuat matriks dengan ordo  $n \times n$  di mana  $n$  sama dengan nilai elemen terbesar dari matriks *grayscale* A. Dalam hal ini, nilai elemen terbesar matriks A adalah 3, maka dibuat matriks ukuran  $3 \times 3$  dengan indeks dimulai dari 0 seperti terlihat pada Gambar 6.

$$B = \begin{bmatrix} & 0 & 1 & 2 & 3 \\ 0 & & & & \\ 1 & & & & \\ 2 & & & & \\ 3 & & & & \end{bmatrix}$$


Gambar 6. Matriks GLCM  $3 \times 3$

- o Penentuan nilai matriks B dimulai dari elemen (0,0). Untuk mengisi matriks B dilakukan iterasi terhadap setiap 2 blok matriks A untuk mengecek nilai elemennya. Sebagai contoh, membuat matriks GLCM dengan sudut 0°, maka arah iterasi yang dilakukan yaitu horizontal (sesuai dengan arah sudut matriks GLCM).
- o Iterasi pertama dilakukan untuk mengecek jumlah matriks ketetanggaan yang bernilai (0,0). Iterasi dimulai dari elemen (0,0) dan (0,1) pada matriks A. Pengecekan berlaku dua arah, artinya elemen (0,0) dan (0,1) dicek sebanyak dua kali dengan arah berlawanan. Jumlah matriks ketetanggaan dengan nilai (0,0) ditulis pada matriks B elemen (0,0). Selanjutnya geser satu blok ke kanan untuk mengecek elemen matriks (0,1) dan (0,2). Lakukan pengecekan hingga elemen (0,2) dan (0,3) kemudian pindah ke baris elemennya. Gambar 7 menunjukkan proses pembentukan matriks GLCM pada sudut 0°.



Gambar 7. Pembentukan matriks GLCM sudut 0°

- o Iterasi selanjutnya dilakukan untuk mengecek jumlah matriks ketetanggaan yang bernilai (0,1) untuk diisi pada matriks B elemen (0,1), begitu seterusnya hingga elemen terakhir pada matriks B.
- o Hal yang sama dilakukan untuk membuat matriks GLCM dengan sudut 45°, 90° dan 135° namun dengan arah yang berbeda. Matriks GLCM sudut 45° dibuat dengan arah diagonal-kanan (*right-diagonal*), sudut 90° dengan arah vertikal, sedangkan sudut 135° dibuat dengan arah diagonal-kiri (*left-diagonal*) seperti yang terlihat pada Gambar 8.



Gambar 8. Arah matriks GLCM a. Sudut 45°. (b) Sudut 90°. (c) Sudut 135°

- o Didapatkan empat buah matriks GLCM seperti pada Gambar 9.

|     |   |   |   |   |
|-----|---|---|---|---|
| B = | 4 | 2 | 1 | 0 |
|     | 2 | 4 | 0 | 0 |
|     | 1 | 0 | 6 | 1 |
|     | 0 | 0 | 1 | 2 |
| (a) |   |   |   |   |
| C = | 4 | 1 | 0 | 0 |
|     | 1 | 2 | 3 | 0 |
|     | 0 | 2 | 4 | 1 |
|     | 0 | 0 | 1 | 0 |
| (b) |   |   |   |   |
| D = | 6 | 0 | 2 | 0 |
|     | 0 | 4 | 2 | 0 |
|     | 2 | 2 | 2 | 2 |
|     | 0 | 0 | 2 | 0 |
| (c) |   |   |   |   |
| E = | 2 | 1 | 3 | 0 |
|     | 1 | 2 | 1 | 0 |
|     | 3 | 1 | 0 | 2 |
|     | 0 | 0 | 2 | 0 |
| (d) |   |   |   |   |

Gambar 9. Hasil pembentukan matriks GLCM (a)  $\theta = 0^\circ$   $d = 1$ . (b)  $\theta = 45^\circ$   $d = 1$ . (c)  $\theta = 90^\circ$   $d = 1$ . (d)  $\theta = 135^\circ$   $d = 1$

- o Matriks GLCM kemudian dinormalisasi agar jumlah seluruh elemennya sama dengan satu. Gambar 10 merupakan hasil normalisasi terhadap matriks B.

|     |      |      |      |      |      |
|-----|------|------|------|------|------|
| F = | 0.18 | 0.06 | 0.06 | 0.03 | 0.09 |
|     | 0.06 | 0    | 0.06 | 0.03 | 0.03 |
|     | 0.06 | 0.06 | 0    | 0    | 0.03 |
|     | 0.03 | 0.03 | 0    | 0    | 0    |
|     | 0.09 | 0.03 | 0.03 | 0    | 0.06 |

Gambar 10. Matriks GLCM yang telah dinormalisasi

Proses normalisasi menghasilkan 4 matriks GLCM normal yang kemudian akan digunakan pada tahap selanjutnya.

## 2. Perhitungan nilai fitur GLCM


Matriks GLCM yang telah dihasilkan pada tahap sebelumnya digunakan untuk menghitung 5 fitur GLCM yang terdiri atas ASM (*Energy*), *Contrast*, *IDM (Homogeneity)*, *Entropy* dan *Correlation*.

## A3. Klasifikasi

Konsep SVM dapat dijelaskan secara sederhana sebagai usaha mencari *hyperplane* terbaik yang memisahkan dua buah kelas pada *input space*. Prinsip dasar SVM adalah memisahkan dua buah kelas, misalnya segar atau tidaknya suatu daging, hujan atau tidak hujan dan lain-lain. Selanjutnya SVM dikembangkan agar bekerja pada permasalahan yang memiliki lebih dari dua kelas. Dalam kasus klasifikasi yang secara linier bisa dipisahkan, dapat digunakan fungsi pemisah seperti pada persamaan (15).

$$f(x) = w^T \cdot x + b \quad (15)$$

Di mana  $w = \sum_i a_i \cdot S_i$  dan  $b$  adalah *bias*, sedangkan  $x$  merupakan nilai dari citra uji. *Hyperplane* pemisah terbaik antara kedua kelas dapat ditemukan dengan mengukur *margin hyperplane* tersebut dan mencari titik maksimalnya. *Margin* adalah jarak antara *hyperplane* tersebut dengan *pattern* terdekat dari masing-masing kelas. *Pattern* yang paling dekat ini disebut sebagai *support vector* [12]. Garis ab pada Gambar 11 menunjukkan *hyperplane* terbaik, yaitu yang terletak tepat pada tengah-tengah kedua kelas sedangkan lingkaran dan kotak yang terletak pada garis putus-putus cd dan ef merupakan *support vector*.



Gambar 11. Margin hyperplane

Setiap data latih dinyatakan oleh  $(x_i, y_i)$ , di mana  $i=1,2,\dots,N$ , dan  $x_i = \{x_{i1}, x_{i2}, \dots, x_{iq}\}^T$  merupakan atribut

(fitur) set untuk data latih ke-i.  $q$  merupakan data  $x_i$  ke- $q$ .  $y_i \in \{-1, +1\}$  menyatakan label kelas.

|          |          |          |     |          |
|----------|----------|----------|-----|----------|
| $x_1 =$  | $x_{11}$ | $x_{12}$ | ... | $x_{1q}$ |
| $x_2 =$  | $x_{21}$ | $x_{22}$ | ... | $x_{2q}$ |
| $\vdots$ | $\vdots$ | $\vdots$ |     | $\vdots$ |
| $x_q =$  | $x_{q1}$ | $x_{q2}$ | ... | $x_{qq}$ |

Gambar 12. Ilustrasi SVM

*Hyperplane* klasifikasi linier SVM, seperti pada Gambar 2.1, dinotasikan seperti pada persamaan (16).

$$w \cdot x_i + b = 0 \quad (16)$$

Data  $x_i$  yang masuk ke dalam kelas -1 adalah data yang memenuhi pertidaksamaan (17).

$$w \cdot x_i + b \leq -1 \quad (17)$$




Sementara data  $x_i$  yang masuk ke dalam kelas +1 adalah data yang memenuhi pertidaksamaan (18).

$$w \cdot x_i + b \geq +1 \quad (18)$$

#### B. Pengumpulan Data

Sebanyak 1500 citra retakan (*crack*) bangunan yang diambil menggunakan kamera di lokasi gempa Kabupaten Lombok Utara, NTB pada tahun 2018. Terdapat tiga jenis retakan (*crack*) bangunan yang diambil yaitu ringan, sedang dan berat. Tabel 2 menunjukkan contoh gambar retakan (*crack*) dalam kategori ringan, sedang dan berat.

TABEL 2. CONTOH DATA RETAKAN

| Ringan  | Sedang  | Berat   |
|---|---|---|
|  |  |  |

#### C. Training, Pengujian dan Analisa

Fitur citra yang telah disimpan di dalam *database* digunakan sebagai *dataset training* yang akan menjadi pembelajaran sistem untuk memilih jenis retakan (*crack*) mana yang sesuai. Sebagai tolak ukur tingkat akurasi dari aplikasi dilakukan uji coba dengan mengambil gambar salah satu retakan secara acak dan melakukan pengujian seberapa besar akurasi yang dihasilkan. Hasil pengujian ini akan menjadi bahan analisa untuk meningkatkan tingkat akurasi sistem.

Perhitungan akurasi merupakan salah satu hal yang penting dalam pengenalan pola. Proses ini dilakukan sebagai salah satu tolak ukur evaluasi dalam suatu sistem. Evaluasi dapat menggunakan berbagai cara salah satunya yaitu menggunakan *confusion matrix* seperti yang tertera Tabel 3.

TABEL 3. CONFUSION MATRIX

|              |             | Predict class |             |
|--------------|-------------|---------------|-------------|
|              |             | Retakan       | Non Retakan |
| Actual Class | Retakan     | TP            | FN          |
|              | Non Retakan | FP            | TN          |

Tabel 3 akan menjadi acuan untuk melakukan perhitungan terhadap akurasi dari model yang dihasilkan. *Class A*, dan *B* secara berturut-turut merepresentasikan *class* untuk retakan dan non-retakan. Pada tabel *confusion matrix* di atas, *true positive* (TP) adalah jumlah *record* positif yang diklasifikasikan sebagai positif, *false positive* (FP) adalah jumlah *record* negatif yang diklasifikasikan sebagai positif, *false negatives* (FN) adalah jumlah *record* positif yang diklasifikasikan sebagai negatif, *true negatives* (TN) adalah jumlah *record* negatif yang diklasifikasikan sebagai negatif. Setelah data uji diklasifikasikan maka akan didapatkan *confusion matrix* sehingga dapat dihitung akurasi dengan menggunakan Persamaan (19) [18].

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} \times 100\% \quad (19)$$

### IV. HASIL DAN PEMBAHASAN

#### A. Pengumpulan Data

Pada penelitian ini digunakan *dataset* dari penelitian sebelumnya yang meneliti tentang retakan pada bangunan. *Dataset* tersebut berjumlah 40.000 citra dengan citra retak sejumlah 20.000 dan 20.000 citra non-retak [19]. Dari *dataset* tersebut, peneliti kemudian membagi komposisi 70% data latih berbanding 30% data uji sehingga dihasilkan data latih sebanyak 14.000 citra retak dan 14.000 citra non-retak, serta 6.000 citra retak dan 6.000 citra non-retak sebagai data ujian. Sedangkan untuk mencari model terbaik digunakan 1.200 citra dari sumber data yang telah disebutkan di atas dengan spesifikasi 420 citra retak dan 420 citra non-retak sebagai data latih model, serta 180 citra retak dan 180 citra non-retak sebagai data pengujian dari pengujian untuk mencari model terbaik.

#### B. Preprocessing

Pada bagian *preprocessing*, akan dilakukan 4 tahapan proses yaitu *resize*, *binarization*, *morphological filtering* (median filter), dan *segmentation*. Berikut penjelasan dan uraian dari setiap tahapan proses tersebut:


##### B.1. Resize

Data yang digunakan pada penelitian ini tidak perlu dilakukan proses *resize* dan *cropping* karena data yang digunakan sudah terstandarisasi dan memiliki ukuran yang sama untuk seluruh citra retak dan/atau non-retaknya, yaitu 227x227 piksel pada ruang warna RGB.



### B.2. Binarization


*Preprocessing* selanjutnya adalah tahapan binarisasi yaitu mengubah ruang warna yang awalnya RGB ke hitam putih dengan batas abang 127. Maksudnya nilai piksel di bawah 127 akan diubah jadi 0, dan 1 apabila lebih besar atau sama dengan 127. Berikut perubahan citra dari RGB ke biner:



Gambar 13. Hasil konversi RGB ke biner

### B.3. Morphological Filtering


*Preprocessing* selanjutnya adalah tahapan *morphological filtering* yaitu proses menghilangkan *noise* atau bintik-bintik kecil sehingga hasil citra filter lebih jernih dan bersih. Metode *filtering* yang digunakan adalah median *filtering* di mana proses filter menggunakan nilai median atau nilai tengahnya. Berikut perubahan citra hasil median *filtering*:



Gambar 14. Citra hasil median filtering

### B.4. Segmentation

*Preprocessing* yang terakhir adalah *segmentation* yaitu mengambil bagian retakannya saja pada suatu citra. Maksudnya adalah citra akan dipotong dan hanya diambil bagian retakannya saja. Berikut citra hasil *segmentation*:



Gambar 15. Citra hasil segmentation

### C. Extraction Feature dengan GLCM

Citra yang telah melewati proses *preprocessing* akan masuk ke dalam tahap ekstraksi fitur yaitu citra akan diambil fitur-fitur pentingnya dan akan di simpan ke dalam variabel untuk nantinya akan dijadikan pembanding

dengan citra yang lainnya. Pada penelitian ini digunakan metode GLCM sebagai fitur ekstraksi tekstur dari permukaan citra retakan pada bangunan. Di dalam GLCM sendiri memiliki banyak sekali fitur ekstraksi, namun terdapat 5 fitur yang paling berpengaruh sesuai dengan hasil penelitian sebelumnya [16] yaitu *Energy*, *Contrast*, *Correlation*, *Homogeneity* dan *Entropy*. GLCM memiliki 4 sudut yaitu  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$ , dan  $135^\circ$  sehingga total fitur ekstraksi yang akan di dapatkan dalam satu citra adalah 20 fitur serta di tambah 2 fitur lagi yaitu *mean* dan standar deviasi. Jadi totalnya adalah 22 fitur ekstraksi. Pada Tabel 4 merupakan salah satu contoh hasil ekstraksi GLCM citra retak dan citra non retak.

TABEL 4. HASIL EKSTRAKSI FITUR GLCM

| No. | Fitur                   | Hasil Retakan | Hasil Non Retakan |
|-----|-------------------------|---------------|-------------------|
| 1   | Energi $0^\circ$        | 0.7969        | 0.9767            |
| 2   | Energi $45^\circ$       | 0.7923        | 0.9767            |
| 3   | Energi $90^\circ$       | 0.8010        | 0.9768            |
| 4   | Energi $135^\circ$      | 0.7947        | 0.9767            |
| 5   | Contrast $0^\circ$      | 0.0200        | 0.0073            |
| 6   | Contrast $45^\circ$     | 0.0279        | 0.0117            |
| 7   | Contrast $90^\circ$     | 0.0135        | 0.0044            |
| 8   | Contrast $135^\circ$    | 0.0255        | 0.0117            |
| 9   | Homogeneity $0^\circ$   | 0.9900        | 0.9963            |
| 10  | Homogeneity $45^\circ$  | 0.9860        | 0.9941            |
| 11  | Homogeneity $90^\circ$  | 0.9932        | 0.9978            |
| 12  | Homogeneity $135^\circ$ | 0.9873        | 0.9941            |
| 13  | Entropy $0^\circ$       | 0.1813        | 0.0333            |
| 14  | Entropy $45^\circ$      | 0.1904        | 0.0313            |
| 15  | Entropy $90^\circ$      | 0.1726        | 0.0324            |
| 16  | Entropy $135^\circ$     | 0.1871        | 0.0313            |
| 17  | Correlation $0^\circ$   | 0.8913        | 0.5425            |
| 18  | Correlation $45^\circ$  | 0.8452        | -0.0026           |
| 19  | Correlation $90^\circ$  | 0.9272        | 0.7670            |
| 20  | Correlation $135^\circ$ | 0.8590        | -0.0037           |
| 21  | Mean                    | 1             | 1                 |
| 22  | SD                      | 0             | 0                 |

### D. Pelatihan dengan SVM

Pada tahapan pelatihan dengan metode klasifikasi SVM ini, data hasil ekstraksi akan di masukan sebagai data latih dan di simpan. Lalu ketika akan melakukan pengujian, data latih yang sudah disimpan tersebut tinggal di *load*.

### E. Pengujian dengan SVM

Pada tahapan pengujian dengan metode klasifikasi SVM ini, data hasil *training* akan *load* dan dilanjutkan dengan proses uji kepada setiap citra *input*. Hasilnya akan didapatkan citra *input* tersebut masuk ke kelas retakan atau non retakan.

### F. Hasil

Pada penelitian ini akan dicari 2 hasil, yaitu hasil pelatihan dan hasil pengujian. Hasil pelatihan digunakan

untuk mencari model terbaik dengan mencari kombinasi *cross classification* terbaik dalam mengekstrak ciri dari citra retak dan non-retak. Sedangkan hasil pengujian digunakan untuk menguji model terbaik yang didapatkan dari hasil pelatihan untuk diterapkan pada jumlah data yang berbeda. Berikut adalah uraian hasil pelatihan dan hasil pengujian yang sudah didapatkan.

### F.1. Hasil Pelatihan

TABEL 5. SPESIFIKASI JUMLAH DATA LATIH DAN UJI UNTUK TAHAP PENGUJIAN

| Jenis Data | Spesifikasi |           | Total |
|------------|-------------|-----------|-------|
|            | Retak       | Non-Retak |       |
| Data Latih | 420         | 420       | 840   |
| Data Uji   | 180         | 180       | 360   |
| Jumlah     |             |           | 1200  |

#### 1. Hasil Penelitian dengan kombinasi *cross classification*

|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | Akurasi(%) |
|-------------------|----|----|----|----|----|----|----|----|----|-----|------------|
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 93,88889   |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 90,83333   |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 91,94444   |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 95         |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 98,05556   |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 96,94444   |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 97,5       |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 98,05556   |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 97,22222   |
|                   | K1 | K2 | K3 | K4 | K5 | K6 | K7 | K8 | K9 | K10 | 96,11111   |
| Rata-rata akurasi |    |    |    |    |    |    |    |    |    |     | 95,55556   |

**Keterangan:**

■ : Data Latih ■ : Data Uji

Gambar 16. Pelatihan dengan kombinasi cross classification

Didapatkan dua model yang memiliki akurasi tertinggi yaitu model pertama dengan kombinasi K1, K5, K6, K7, K8, K9, K10 sebagai data latih, K2, K3, K4 sebagai data uji, serta model kedua dengan kombinasi K1, K2, K3, K4, K8, K9, K10 sebagai data latih, K5, K6, K7 sebagai data uji dengan akurasi mencapai 98,05556%. Sehingga akan dilakukan pengujian kembali untuk mendapatkan model terbaik dengan menambah jumlah data uji menjadi 720 data.

Pada pengujian kedua di dapatkan sedikit penurunan pada kedua model. Pada model pertama didapatkan hasil akurasi 96,66667%, sedangkan pada model kedua didapatkan hasil akurasi 97,5%. Sehingga model kedua menjadi model yang terbaik (K1, K2, K3, K4, K8, K9, K10 sebagai data latih, K5, K6, K7 sebagai data uji). Maka model ini akan digunakan untuk tahap pelatihan selanjutnya.

#### 2. Hasil Penelitian dengan kombinasi fitur ekstraksi

TABEL 6. KOMBINASI DENGAN 360 DATA UJI

| Jumlah Fitur | Akurasi(%) |
|--------------|------------|
| 1            | 94,44444   |
| 2            | 97,77778   |

|       |          |
|-------|----------|
| 3     | 97,5     |
| 4     | 98,05556 |
| 5     | 98,05556 |
| Semua | 98,05556 |

TABEL 7. KOMBINASI DENGAN 720 DATA UJI

| Jumlah Fitur | Akurasi(%) |
|--------------|------------|
| 1            | 95         |
| 2            | 97,77778   |
| 3            | 97,63889   |
| 4            | 98,05556   |
| 5            | 97,5       |
| Semua        | 97,5       |

**Keterangan urutan:** *Energy, Contras, Homogeneity, Entropy, Correlation, Mean* dan Standar Deviasi.

Pada tahapan pelatihan menggunakan 360 data uji dihasilkan model terbaik yang menggunakan sekurangnya 4 fitur dalam pengujannya. Karena model yang didapatkan lebih dari satu, maka selanjutnya diuji kembali dengan menggunakan 720 data uji. Sehingga didapatkan model terbaik dengan fitur ekstraksi yang digunakan berjumlah 4 fitur yaitu *Energy, Contras, Homogeneity* dan *Entropy*. Akurasi yang didapatkan yaitu 98,05556%. Maka model ini akan digunakan untuk tahap pelatihan selanjutnya.

#### 3. Hasil Penelitian dengan kombinasi sudut GLCM

TABEL 8. KOMBINASI DENGAN 360 DATA UJI

| Sudut | Akurasi  |
|-------|----------|
| 0°    | 97,77778 |
| 45°   | 98,05556 |
| 90°   | 97,22222 |
| 135°  | 97,22222 |
| Semua | 98,05556 |

TABEL 9. KOMBINASI DENGAN 1440 DATA UJI

| Sudut | Akurasi  |
|-------|----------|
| 45°   | 96,45833 |
| Semua | 97,01389 |

Pada tahapan penelitian dengan menggunakan 360 data uji, di dihasilkan dua model terbaik yaitu model dengan sudut 45° dan model yang menggunakan semua sudut. Hasil akurasinya mencapai 98,05556%. Selanjutnya akan dilakukan pengujian berikutnya untuk menentukan model terbaik dengan menggunakan 1440 data uji. Sehingga didapatkan model terbaik yaitu model dengan penggunaan semua sudut yaitu sudut 0°, 45°, 90°, dan 135° dengan akurasi 97,01389%. Maka model ini dinyatakan sebagai model terbaik yang

selanjutnya akan digunakan untuk tahap pengujian dengan menggunakan data yang lebih banyak.

## F.2. Hasil Pengujian

Pada tahap ini, hasil pelatihan akan digunakan dan dilakukan pengujian. Kombinasi terbaik yang dihasilkan pada tahap pelatihan akan menjadi model terbaik dan diterapkan pada tahap pengujian ini. Pada Tabel 11 merupakan hasil pengujiannya dengan model yang telah didapatkan.

TABEL 10. SPESIFIKASI JUMLAH DATA LATIH DAN UJI UNTUK TAHAP PENGUJIAN

| Jenis Data | Spesifikasi |           | Total  |
|------------|-------------|-----------|--------|
|            | Retak       | Non-Retak |        |
| Data Latih | 14.000      | 14.000    | 28.000 |
| Data Uji   | 6.000       | 6.000     | 12.000 |
| Jumlah     |             |           | 40.000 |

TABEL 11. HASIL PENGUJIAN

| Perhitungan                  | Retak | Non-retak | Rata-rata |
|------------------------------|-------|-----------|-----------|
| Akurasi dgn 820 data latih   | 96    | 96,7      | 96,35     |
| Akurasi dgn 28000 data latih | 82    | 99,38     | 90,69     |

## F.3. Hasil Pengujian dengan Data Gempa Lombok

### 1. Pengujian dengan 2 kelas

Pada tahap ini, hasil pelatihan akan digunakan dan dilakukan pengujian terhadap data gempa lombok. Pada Tabel 13 merupakan hasil pengujiannya dengan model yang telah didapatkan.

TABEL 12. SPESIFIKASI JUMLAH DATA LATIH DAN UJI UNTUK TAHAP PENGUJIAN

| Jenis Data | Spesifikasi |        | Total |
|------------|-------------|--------|-------|
|            | Berat       | Ringan |       |
| Data Latih | 28          | 28     | 56    |
| Data Uji   | 12          | 12     | 24    |
| Jumlah     |             |        | 80    |

TABEL 13. HASIL PENGUJIAN

| Perhitungan | Berat | Ringan | Rata-rata |
|-------------|-------|--------|-----------|
| Akurasi     | 83,33 | 83,33  | 83,33     |

### 2. Pengujian dengan 3 kelas

TABEL 14. SPESIFIKASI JUMLAH DATA LATIH DAN UJI UNTUK TAHAP PENGUJIAN

| Jenis Data | Spesifikasi |        |        | Total |
|------------|-------------|--------|--------|-------|
|            | Berat       | Sedang | Ringan |       |
| Data Latih | 21          | 21     | 21     | 63    |
| Data Uji   | 9           | 9      | 9      | 27    |
| Jumlah     |             |        |        | 90    |


TABEL 15. HASIL PENGUJIAN

| Perhitungan | Berat | Sedang | Ringan | Rata-rata |
|-------------|-------|--------|--------|-----------|
| Akurasi     | 77,78 | 44,44  | 88,89  | 70,37     |

## F.4. Analisa Hasil Pelatihan dan Pengujian

### 1. Analisa pada pelatihan


- Pelatihan dengan kombinasi *cross classification*



Gambar 17. Diagram pelatihan dengan kombinasi *cross classification*

Pada pelatihan ini di dapatkan 2 model dengan tingkat akurasi tertinggi yaitu model 5 dan model 8. Sehingga model ini yang akan di bawa ke tahap pelatihan selanjutnya.


- Pelatihan dengan kombinasi fitur ekstraksi



Gambar 18. Diagram pelatihan kombinasi fitur ekstraksi


Pada pelatihan ini didapatkan kombinasi 4 fitur lebih unggul daripada kombinasi yang lain. Sehingga kombinasi 4 fitur ini akan digunakan untuk tahap pelatihan selanjutnya.

- Pelatihan dengan kombinasi sudut GLCM



Gambar 19. Diagram pelatihan dengan kombinasi sudut GLCM pertama



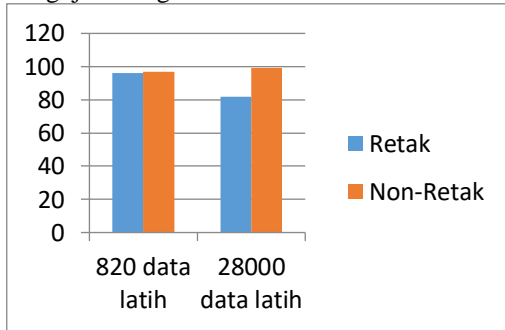


Gambar 20. Diagram pelatihan dengan kombinasi sudut GLCM kedua

Pada pelatihan dengan kombinasi sudut GLCM, didapatkan kombinasi ke empat sudut pada GLCM menjadi mode terbaik, sehingga akan dijadikan model pada tahap pengujian.

## 2. Analisa pada pengujian


- Pengujian dengan 40.000 *dataset*



Gambar 21. Diagram pengujian 40000 dataset

Pada pengujian ini didapatkan rata-rata akurasi tertinggi pada data latih 820 dengan akurasi 96,35%. Sehingga dapat dikatakan bahwa kombinasi GLCM dengan klasifikasi SVM memiliki performa yang baik pada studi kasus klasifikasi retakan (*crack*) pada bangunan.


- Pengujian dengan data Gempa Lombok
  - Pengujian 2 kelas



Gambar 22. Diagram pengujian 2 kelas

Pada pengujian dengan data gempa Lombok 2 kelas (Berat dan Ringan) didapatkan bahwa kombinasi GLCM dan SVM masih baik dengan tingkat akurasi di atas 80% yaitu 83,33%.

- Pengujian 3 kelas



Gambar 23. Diagram pengujian 3 kelas

Pada pengujian dengan data gempa Lombok 3 kelas (Berat, Sedang dan Ringan) didapatkan bahwa kombinasi GLCM dan SVM mengalami penurunan dengan tingkat akurasi berat, sedang dan ringan berturut-turut yaitu 77,78%, 44,44% dan 89,89%. Sehingga rata-rata akurasinya adalah 70,37%.

## V. KESIMPULAN DAN SARAN

### A. Kesimpulan

Berdasarkan hasil penelitian yang sudah didapatkan, dapat disimpulkan bahwa:

1. Metode ekstraksi fitur GLCM dengan klasifikasi SVM merupakan kombinasi yang tepat dalam mengklasifikasikan retakan (*crack*) pada bangunan.
2. Model ekstraksi fitur GLCM terbaik yang didapatkan dalam mengklasifikasikan retakan (*crack*) sehingga mendapatkan tingkat akurasi tinggi adalah yang pertama yaitu menggunakan kombinasi 70% banding 30% pada *dataset* dengan K1, K2, K3, K4, K8, K9, K10 sebagai data latih, K5, K6, K7 sebagai data uji. Selanjutnya menggunakan 4 fitur ekstraksi yaitu *Energy*, *Contras*, *Homogenity* dan *Entropy*. Serta menggunakan ke empat sudut GLCM yaitu  $0^0$ ,  $45^0$ ,  $90^0$ , dan  $135^0$ .
3. Performa kombinasi GLCM dengan SVM pada kasus klasifikasi retakan (*crack*) pada bangunan ini sudah tepat dikarenakan pada tahap pengujian menghasilkan tingkat akurasi yang cukup tinggi. Pada pengujian dengan jumlah data 40.000, didapatkan akurasi tertinggi mencapai 96,35%. Sedangkan pada saat pengujian dengan menggunakan data gempa Lombok didapatkan hasil untuk 2 kelas (Berat dan Ringan) mencapai akurasi 83,33% dan untuk 3 kelas (Berat, Sedang dan Ringan) mencapai akurasi 70,37%.

### B. Saran

Dari hasil penelitian yang sudah didapatkan terdapat beberapa catatan saran untuk dapat diperbaiki dan dikembangkan pada penelitian selanjutnya, antara lain:

1. Penggunaan metode ekstraksi fitur yang tepat sangat mempengaruhi hasil dari klasifikasi, sehingga

peneliti menyarankan untuk gunakan metode ekstraksi fitur yang tepat sebelum melakukan proses klasifikasi.

2. Faktor lain dalam menentukan hasil penelitian adalah kualitas dari *dataset* nya. Sehingga peneliti menyarankan untuk melakukan standarisasi data terlebih dahulu sebelum masuk ke dalam tahap ekstraksi dan klasifikasi.

#### DAFTAR PUSTAKA

- [1] K. Septia, "Lombok Diguncang 1.973 Gempa dalam Satu Bulan," *Kompas.com*, 2018. [Daring]. Tersedia pada: <https://regional.kompas.com/read/2018/08/30/09163821/lombok-diguncang-1973-gempa-dalam-satu-bulan>.
- [2] N. Lihayati, R. E. Pawening, M. Furqan, J. T. Informatika, dan G. L. C. Matrix, "Klasifikasi Jenis Daging Berdasarkan Tekstur Menggunakan Metode Gray Level Coocurent Matrix," *Pros. SENTIA*, vol. 8, no. 1994, hal. 305–310, 2016.
- [3] H. Wijayanto, "Klasifikasi Batik Menggunakan Metode K-Nearest Neighbour Berdasarkan Gray Level Co-Occurrence Matrices ( GLCM )," *Jur. Tek. Inform. FIK UDINUS*, hal. 1–7, 2015.
- [4] N. Neneng, K. Adi, dan R. Isnanto, "Support Vector Machine Untuk Klasifikasi Citra Jenis Daging Berdasarkan Tekstur Menggunakan Ekstraksi Ciri Gray Level Co-Occurrence Matrices (GLCM)," *J. Sist. Inf. Bisnis*, vol. 6, no. 1, hal. 1–10, 2016.
- [5] R. Anggraini, "Klasifikasi Jenis Kualitas Keju Dengan Menggunakan Metode Gray Level Co-occurrence Matrix (GLCM) dan Support Vector Machine (SVM) Pada Citra Digital," *e-Proceeding Eng.*, vol. 4, no. 2, hal. 2035–2042, 2017.
- [6] V. C. Bharathi dan M. K. Geetha, "Segregated Handwritten Character Recognition using GLCM features," *Int. J. Comput. Appl.*, vol. 84, no. 2, hal. 1–7, 2013.
- [7] J. L. Nunes, M. Piquerez, L. Pujadas, E. Armstrong, A. Fernández, dan F. Lecumberry, "Beef quality parameters estimation using ultrasound and color images," *Nunes al. BMC Bioinforma.*, vol. 16, no. 4, hal. 1–12, 2015.
- [8] R. Widodo, A. W. Widodo, dan A. Supriyanto, "Pemanfaatan Ciri Gray Level Co-Occurrence Matrix ( GLCM ) Citra Buah Jeruk Keprok ( Citrus reticulata Blanco ) untuk Klasifikasi Mutu," *J. Pengemb. Teknol. Inf. dan Ilmu Komput.*, vol. 2, no. 11, hal. 5769–5776, 2018.
- [9] A. Mohan dan S. Poobal, "Crack detection using image processing: A critical review and analysis," *Alexandria Eng. J.*, vol. 57, no. 2, hal. 787–798, Jun 2018.
- [10] S. Kabir, "Imaging-based detection of AAR induced map-crack damage in concrete structure," *NDT E Int.*, vol. 43, no. 6, hal. 461–469, Sep 2010.
- [11] A. M. Puspitasari, D. E. Ratnawati, dan A. W. Widodo, "Klasifikasi Penyakit Gigi Dan Mulut Menggunakan Metode Support Vector Machine," *J. Pengemb. Teknol. Inf. dan Ilmu Komput.*, vol. 2, no. 2, hal. 802–810, 2018.
- [12] N. Vassilieva, "Content Based Image Retrieval (CBIR)," *2nd Russ. Summer Sch. Inf. Retr.*, hal. 1–9, 2008.
- [13] A. S. Nugroho, A. B. Witarto, dan D. Handoko, "Support Vector Machine," *IlmuKomputer.Com*, hal. 1–11, 2003.
- [14] M. H. Beyer, "Gray Level Co-occurrence Matrix," 2008. [Daring]. Tersedia pada: [http://www.fp.ucalgary.ca/mhallbey/the\\_glcm.html](http://www.fp.ucalgary.ca/mhallbey/the_glcm.html). [Diakses: 05-Sep-2018].
- [15] R. M. Haralick dan K. Shanmugam, "Textural Features for Image Classification," *IEEE Trans. Syst. Man. Cybern.*, vol. SMC-3, no. 6, hal. 610–621, 1973.
- [16] T. Sree Sharmila, "Efficient analysis of satellite image denoising and resolution enhancement for improving classification accuracy," hal. 1–7, 2014.
- [17] Noordama, "Identifikasi varietas durio zibethinus berdasarkan sebaran trikoma daun menggunakan glcm dan knn noordama," *Inst. Pertan. BOGOR*, 2014.
- [18] M. Paramita dan R. Ely, "Prediksi Nilai Proyek Akhir Mahasiswa Menggunakan Algoritma Klasifikasi Data Mining," *Sist. Inf.*, vol. 11, no. November, hal. 1–7, 2015.
- [19] Ç. F. Özgenel, "Concrete Crack Images for Classification," vol. 1. Mendeley, 15-Jan-2018.